

基于 CNN 与 Transformer 混合模型的口罩人脸识别方法^{*}

姜绍忠, 姚克明, 陈磊, 王中洲, 郭复澳
(江苏理工学院 电子信息工程学院, 江苏 常州 213001)

摘要: 针对疫情背景下,因佩戴口罩导致普通人脸识别算法失效的问题,提出一种基于卷积神经网络(CNN)与 Transformer 混合模型的口罩人脸识别方法。结合了 CNN 与 Transformer 的优点,能够很好地处理局部和全局信息,使模型拥有更好的性能及泛化能力。在卷积模块引入空间注意力模块,加强模型对于鲁棒特征信息的提取,使用 Sub-center Arcface 损失函数,进一步提高模型的分类精度。在人工合成的口罩人脸数据集和真实的戴口罩人脸数据集上的实验表明,本文模型能够同时有效处理戴口罩和不戴口罩人脸识别任务,拥有较小的参数量的同时,具备较高的识别精度。

关键词: 口罩人脸识别; 混合模型; 空间注意力机制; Sub-center Arcface 损失函数

中图分类号: TP391.41

文献标识码: A

文章编号: 1000-9787(2023)01-0144-05

Masked face recognition method based on CNN and Transformer hybrid model^{*}

JIANG Shaozhong, YAO Keming, CHEN Lei, WANG Zhongzhou, GUO Fuaao
(School of Electrical Information Engineering, Jiangsu University of Technology, Changzhou 213001, China)

Abstract: Aiming at the problem that wearing masks under the background of epidemic situation results in common face recognition algorithm fails, a masked face recognition method is proposed based on convolutional neural network (CNN) and Transformer hybrid model. This method combines the advantages of CNN and Transformer, which can well process local and global information and make the model have better performance and generalization ability. The spatial attention module is introduced into the convolutional module to strengthen the extraction of robust facial feature information by the model. Furthermore Sub-center Arcface loss function is used to further improve the classification precision of the model. Experiments on the synthetic and the real-mask face datasets show that our method can effectively process face recognition task with and without mask, with a small number of references and a high recognition precision.

Keywords: masked face recognition; hybrid mechanism; spatial attention mechanism; Sub-center Arcface loss function

0 引言

为了防止新型冠状病毒肺炎(COVID-19)疫情扩散,在公共场合人们都会佩戴口罩,这对人脸识别造成了巨大的挑战。自 Turk M 等人提出 Eigenface^[1]以来,人脸识别一直是研究的焦点。深度学习使模型可以学习到用于人脸识别的高鉴别度的面部特征。口罩遮挡给人脸识别带来更大的挑战,由于鼻子、嘴巴这2个重要人脸特征被破坏,导致超过半数人脸特征不可用,并且给人脸关键点位置信息带来大量噪声,因此,口罩人脸识别成为人脸识别算法的一大难题^[2]。用深度学习解决口罩人脸识别的难题,首先想到的就是通过增强数据集来提高现有算法对口罩人脸识别的准

确率,文献[3]通过混合戴口罩和不戴口罩的人脸数据集来对模型进行训练以提高现有人脸识别模型性能。文献[4]利用 Triplet loss 对在混合数据集上预训练的模型进行微调,进一步提高人脸识别模型对口罩人脸识别的准确率。随着注意力机制在视觉邻域被广泛地研究,其思想也被带到口罩人脸识别的研究中来,文献[5]采用裁剪,并结合注意力模块使网络更多地关注眼部周围地特征,该方法能够很好地提高对口罩人脸识别的准确率,但却降低了无遮挡场景下人脸识别的性能。文献[6]采用双路的训练策略,提出上半人脸分块注意力,通过这种训练策略引导网络更多地关注到上半人脸。

收稿日期:2022-11-11

^{*} 基金项目:江苏省产学研前瞻性联合研发项目(BY2020023)

近一年来,Transformer 模型由于具有自注意力 (self-attention) 模块强大的全局建模能力,而在计算机视觉中取得了显著的成效,但模型的参数量大,空间复杂度高,导致 Transformer 模型需要大量的数据进行训练,训练成本非常高,且由于缺乏正确的归纳偏置,模型的泛化能力较差,难以移植,这也导致难以将模型部署到下游任务中去。将 Transformer 与卷积神经网络 (convolutional neural network, CNN) 结合能够取得更好的效果^[7-10]。

本文提出一种基于 CNN 与 Transformer 混合模型的口罩人脸识别方法,该方法能兼顾戴口罩人脸识别和不戴口罩人脸识别任务。主干特征提取网络使用的是 CNN 与 Transformer 的混合模型 CoAtNet^[11],在卷积模块引入空间注意力机制模块,使模型能够更多地关注到未被遮挡的人脸部分,提取更多用于身份识别的鲁棒信息,构建分类器时使用了 Sub-center Arcface^[12] 损失函数,进一步优化了模型的识别效果。该方法能结合 CNN 与 Transformer 的优点,提高模型的泛化能力和识别准确率。

1 CNN 与 Transformer 的混合模型

综合考虑模型的泛化能力和模型的容量,最终采用如图 1 所示的架构,输入的图像为 112×112 三通道的三原色 (RGB) 彩色图像,其中,Stage0 为经典卷积,Stage1 和 Stage2 阶段为堆叠的 MBConv 模块,经过卷积模块后,图像进入空间注意力模块,然后,送入相对自注意力模块 (relative self-attention block) Stage3 和 Stage4,最后,将图像表示为特征向量,送入 Sub-center Arcface 分类器中,对人脸进行分类。




图 1 整体结构

1.1 主干特征提取网络

谷歌在 MobileNet^[13] 架构中引入了深度可分离卷积 (depthwise separable convolution), 由于使用 1×1 卷积, 需要的计算量大大减小。在 MobileNetV2^[14] 中又引入了倒置残差 (inverted residuals) 和线性瓶颈 (linear bottleneck) 层。卷积操作可表示为

$$y_i = \sum_{j \in L(i)} w_{i-j} \odot x_j \quad (1)$$

其中, $x_i, y_i \in R^D$, 分别为在位置 i 上的输入与输出, $L(i)$ 为 i 的邻域, 也即为卷积处理的感受野。

Self-attention 的感受野是整个特征图, 并根据 (x_i, y_i) 之间重新归一化的成对相似度计算权重

$$y_i = \sum_{j \in G} \frac{\exp(x_i^T x_j)}{\sum_{k \in G} \exp(x_i^T x_k)} x_j \quad (2)$$

式中 G 为全局空间, $A_{i,j}$ 为注意力权重。以上 2 个公式有以下几个特性:

1) Depthwise 卷积核是一个静态值的输入独立参数, 而注意力权重动态地取决于输入的表示。因此, 自注意力更容易捕捉不同空间位置之间复杂的关系交互, 是处理高级概念时最想要的属性;

2) 注意给定任何位置对 (i, j) , 对应的卷积权重只关心它们之间的相对位移, 即 $i - j$, 而不是 i 或 j 的具体值。由于使用绝对位置嵌入, 标准 Transformer (ViT) 缺少此属性, 这部分解释了当数据集不是很大时, CNN 通常比 Transformers 更好;

3) 感受野的大小是自注意力和卷积之间最重要的区别之一。Transformers 拥有全局感受野, 然而, 一个大的感受野需要更多的计算, 在全局注意力的情况下, 复杂性图像尺寸的平方倍, 这是应用自注意力模型的基本权衡。

综上所述, 最优架构应该是自注意力的输入同时具有自适应加权和全局感受野特性以及 CNN 的平移不变性。所以选择在 SoftMax 初始化之后或之前将全局静态卷积核与自适应注意力矩阵相加, 混合卷积和自注意力的计算公式可表示为

$$y_i = \sum_{j \in G} \left(\frac{\exp(x_i^T x_j)}{\sum_{k \in G} \exp(x_i^T x_k)} + w_{i-j} \right) x_j \quad (3)$$

1.2 空间注意力机制

MBConv 中含有通道注意力 SE (squeeze and excitation)^[15], 通道注意力部分能使更多有利于识别任务的特征通道的权重得以增加, 其他特征通道的权重得以抑制。然而, 遮挡人脸识别任务中, 更应该重点关注空间上的信息, 例如眼睛、眉毛、额头部分的纹理信息, 因此, 引入了空间注意力 (spatial attention) 机制来加强特征提取网络。

空间注意力机制的详细描述如下, 对于输入的特征图 $F \in R^{C \times H \times W}$ 使用尺寸为 $(H, 1)$ 的 Pooling kernel 沿着水平方向做平均池化操作, 使用尺寸为 $(1, W)$ 的 Pooling kernel 沿着垂直方向做平均池化操作, 因此, 高度为 h 时, 第 c 个通道的输出为

$$z_c^h(h) = \frac{1}{W} \sum_{0 \leq j < W} x_c(h, j) \quad (4)$$

同样的, 宽度为 w 的第 c 个通道的输出为

$$z_c^w(w) = \frac{1}{H} \sum_{0 \leq j < H} x_c(j, w) \quad (5)$$

给定一个输入的特征图 $F \in R^{C \times H \times W}$, 则 $W_{avg}^c \in R^{C \times 1 \times W}$, $H_{avg}^c \in R^{C \times H \times 1}$ 分别表示输入特征在水平方向和垂直方向上的聚合特征。对这 2 个聚合的特征进行拼接, 由于维度不同, 需要将特征 H_{avg}^c 转置, 然后将它与 W_{avg}^c 拼接, 假设得到特征层 M_1 , 设定一个超参数 r , 本文 r 取 32, (r 必须为 8 的

倍数),通过 1×1 卷积将拼接的得到的特征层 M_1 的通道数转换为 C/r ,然后对其进行使用 GELU 激活函数和 Batch-Norm 操作,得到特征层 M_2 ,此时的 M_2 混合了原特征图上的水平方向和垂直方向的空间信息。接下来将 M_2 分割为 2 部分,再使用 1×1 卷积将通道数扩回原来的 C ,这 2 部分分别为 W', H' 。最后将原始的特征图与这 2 个包含空间信息的特征层相乘

$$F' = F \odot W' \odot H' \quad (6)$$

其中, \odot 为对应位置元素相乘, F' 为注意力输出。

通过对水平方向和垂直方向上的平均池化,空间注意力模块捕获到这两个方向上的长依赖关系,并且其中的一个方向上保存了另一个方向上的精确位置信息,这有助于网络定位到感兴趣的区域,如图 2 所示。

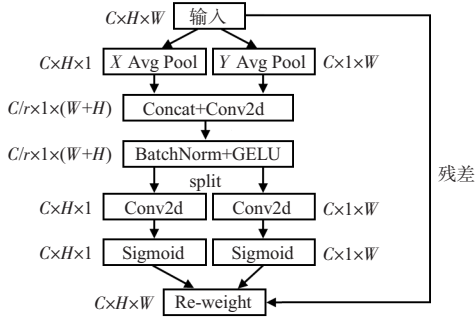


图 2 空间注意力模块

1.3 改进的 Arcface 损失函数

ArcFace 经过特征提取网络提取到的人脸特征向量 x 映射到超球体上,并压缩相同人脸特征向量 x 的余弦距离,扩大不同人脸特征向量 x 的余弦距离

$$L_{\text{arcface}} = -\log \frac{\exp(s \cos(\theta_{y_i} + m))}{\exp(s \cos(\theta_{y_i} + m)) + \sum_{j=1, j \neq y_i}^N \exp(s \cos \theta_j)} \quad (7)$$

其中, s 为超球体的半径, θ 为权重 W 和人脸特征向量 x 之间的夹角, y_i 则是第 i 个人的标签,且权重 W 与人脸特征向量 x 都要进行归一化。ArcFace 通过在此夹角上添加一个间距 m ,进一步增大了不同人脸特征之间的余弦间隔,这样做可以使模型学习到的特征具有更强的判别能力。尽管 ArcFace 已经显示出其在高效和有效的人脸特征嵌入方面的能力,但这种方法假设训练数据是干净的。然而,事实并非如此,尤其数据集规模较大时。在本文使用了 Sub-center ArcFace,它提出了为每个身份使用子类的思想,放宽了类内约束,可以有效的提高噪声下的鲁棒性。

Sub-center ArcFace 具体实现的方式是,为每个身份设置一个足够大的 K ,基于对 $x_i \in R^{512 \times 1}$ 上嵌入的特征和所有的子中心 $W \in R^{N \times K \times 512}$ 的 L_2 归一化步骤,通过矩阵乘法 $W^T x_i$ 得到子类的相似得分 $S \in R^{N \times K}$,然后对 Subclass-wise

的相似得分 $S \in R^{N \times K}$ 采用最大池化得到类的相似得分 $S' \in R^{N \times 1}$ 。Sub-center ArcFace 损失函数可以表示为

$$L_{\text{arcface}} = -\log \frac{\exp(s \cos(\theta_{i, y_i} + m))}{\exp(s \cos(\theta_{i, y_i} + m)) + \sum_{j=1, j \neq y_i}^N \exp(s \cos \theta_{i, j})} \quad (8)$$

其中, $\theta_{i, j} = \arccos(\max_k(W_{jk}^T x_i))$ 。

2 实验过程与结果分析

本节将介绍本文使用到的数据集,以及对数据集所做的处理,模型训练方法,然后分析实验结果,验证本文算法的有效性。所述的模型在 Windows10 下进行训练,使用 GPU 为单个 NVIDIA GTX 3060,训练时的批量大小设置为 64,优化器采用 SGD,初始学习率设置为 0.01。

2.1 数据集

本文使用了一个给标准人脸添加口罩的工具, Mask-TheFace 通过定位人脸关键点,计算人脸角度,有效地为人脸模拟添加口罩,将已有的大规模人脸数据集转换为人工合成的口罩人脸数据集,如图 3 所示,由于现有真实世界人脸口罩数据集规模较小,只适合用来做模型的评估,而不能用于训练。CASIA-WebFace^[16]是最常用的人脸识别训练集之一,是一个包含 10575 不同个人的 494414 张人脸图片的大规模人脸数据集。在添加口罩之前先使用 MTCNN^[17] 将 CASIA-WebFace 当中的人脸图片对齐并裁剪为 112×112 大小,可以避免人脸关键点检测时因为口罩遮挡而失效。验证集采用 MaskTheFace 在 LFW^[18] 上生成的口罩人脸数据集 LFW-Masked,以及真实的人脸数据集 MFR2。MFR2 是一个包含 269 张人脸图片,53 个 ID 的小规模真实人脸数据集,其中,每一个人都包含了佩戴口罩和未佩戴口罩的人脸图片。本文在谷歌上搜索了一些图片将该数据集扩充到 76 人,518 张图片作为真实口罩人脸测试集,命名为 RMF(real masked-face)。

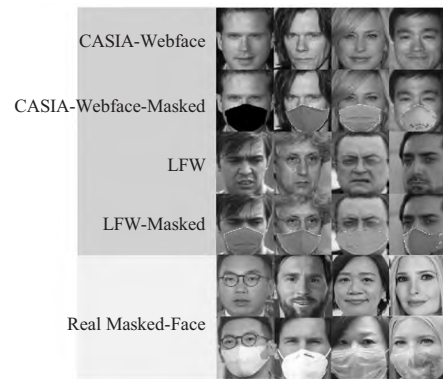


图 3 数据集准备

2.2 实验结果

基于 CNN 的模型选用 Mobilefacenet^[19] 和 Resnet50^[20], 基于 Transformer 的模型选用 ViT 损失函数选用 Arcface。

将其与本文提出的算法作为对比。如表 1 所示,可以看出,不仅在未戴口罩的人脸识别上,本文算法在准确率上有所提升,在佩戴口罩的人脸识别上,本文算法远远优于目前最先进的算法。其中,ViT 模型的识别效率较低,是因为采用的 CASIA-WebFace 数据集数据量较少,基于纯 Transformer 的模型需要大规模的数据和大量的时间进行训练才能达到最优的效果,这无疑增加了大量的成本,由于条件的限制故无法使 ViT 性能达到最优,也证明了混合模型的优越性。

表 1 在 LFW-Masked 和 RMF 上与最先进方法的比较

模型	准确率/%		
	RMF	LFW	LFW-Masked
Mobilefacenet ^[19]	98.04	96.32	91.87
Res50 ^[20]	98.43	96.41	92.33
ViT ^[4]	97.65	95.51	91.74
本文	98.54	97.68	93.36

2.3 消融实验

在 LFW-Masked 和 RMF 数据集上做了消融实验,如表 2。具体来说,将 CoAtNet 作为基线(baseline)网络,然后给网络添加空间(spatial)注意力模块,再将损失函数替换为 Sub-center Arcface。实验中均使用相同的设置进行训练。当添加了空间注意力机制后,网络的准确率在 LFW-Masked 和 RMF 上分别提升了 0.86 个百分点和 0.67 个百分点。此外,在使用了 Sub-center Arcface 之后模型的准确率在 LFW-Masked 和 RMF 分别提升了 0.53 个百分点和 0.51 个百分点。本文算法之所以能取得更好地表现,得益于添加的空间注意力机制,使网络的关注点更集中于未被遮挡的人脸特征,且使用的损失函数能够更好地对口罩人脸进行分类。

表 2 在 LFW-Masked 和 RMF 上的消融实验结果

空间	Sub-center Arcface	准确率/%	
		LFW-Masked	RMF
×	×	96.45	92.34
√	×	97.31	93.01
×	√	96.98	92.85
√	√	97.68	93.36

如表 3 所示,比较 CoAtNet 与其他引入卷积操作的 Transformer 主干网络的模型容量,每秒浮点运算的次数和在 RMF 上的准确率。本文实验中,将这些模型的 Tiny 版本,在 CASIA-WebFace 和 WebFace-masked 上进行训练,然后在 LFW-masked 上测试准确率。可以看出,CoAtNet 能够很好地结合 CNN 与 Transformer 模型地优点,提高了人脸识别的准确率,并且 Transformer 模型在有口罩遮挡这种大面积的遮挡人脸识别中能够起到很好的识别效果,且 CoAtNet 模型的参数量不大,计算复杂度较低,模型的总体性能较其他融合 CNN 结构的 Transformer 网络更优。

表 3 不同混合模型在 RMF 上的对比实验

模型	参数	FLOPs	准确率/%
CVT ^[8]	20 M	4.5 G	91.67
LeViT ^[9]	22 M	4.6 G	91.23
Swin Transformer ^[21]	29 M	4.5 G	91.87
CSwin Transformer ^[22]	23 M	4.3 G	92.12
CoAtNet ^[11]	20M	4.0 G	92.34

3 结束语

本文将 CNN 与 Transformer 混合网络用于训练口罩人脸识别模型,在卷积模块引入空间注意力模块,使模型能够更多地关注到未被遮挡的人脸部分,提取更多用于身份识别的鲁棒信息,损失函数使用了 Sub-center Arcface,进一步提升了模型识别的精度。该方法很好地结合了 CNN 与 Transformer 的优点,提高了模型的泛化能力和识别准确率。分别在 LFW 和 LFW-Masked 上的精度达到 98.54 % 和 97.68 %,实验表明,该模型能够同时兼顾戴口罩和不戴口罩的人脸识别。

参考文献:

[1] TURK M, PENTLAND A. Eigenfaces for recognition[J]. Journal of Cognitive Neuroscience, 1991, 3(1): 71–86.

[2] DUAN Q, ZHANG L. Look more into occlusion: Realistic face frontalization and recognition with boostgan[C]// 2020 IEEE Transactions on Neural Networks; 1–15.

[3] CAO Q, SHEN L, XIE W, et al. VGGFace2: A dataset for recognising faces across pose and age[C]// Proceedings of the 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG), 2018; 67–74.

[4] ANWAR A, RAYCHOWDHURY A. Masked face recognition for secure authentication[J]. arXiv preprint. arXiv: 2008. 11104, 2020.

[5] LI Y, GUO K, LU Y, et al. Cropping and attention based approach for masked face recognition[J]. Applied Intelligence, 2021, 51(5): 3012–3025.

[6] ZHANG Y X, WANG X, SHAKEEL M S, et al. Learning upper patch attention using dual-branch training strategy for masked face recognition[J]. Pattern Recognition, 2022, 126: 108522.

[7] VASWANI A, RAMACHANDRAN P, SRINIVAS A, et al. Scaling local self-attention for parameter efficient visual backbones[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021; 12894–12904.

[8] WU H, XIAO B, CODELLA N, et al. CVT: Introducing convolutions to vision transformers[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021; 22–31.

[9] GRAHAM B, EL-NOUBY A, TOUVRON H, et al. Levit: A vision transformer in convnet’s clothing for faster inference[C]// Proceedings of the IEEE/CVF International Conference on Computer

- Vision, 2021:12259–12269.
- [10] XIA X, LI J, WU J, et al. TRT-ViT: TensorRT-oriented vision transformer[J]. arXiv preprint. arXiv:2205.09579, 2022.
- [11] DAI Z, LIU H, LE Q V, et al. Coatnet: Marrying convolution and attention for all data sizes[J]. Advances in Neural Information Processing Systems, 2021, 34:3965–3977.
- [12] DENG J, GUO J, LIU T, et al. Sub-center arcface: Boosting face recognition by large-scale noisy web faces[C]// European Conference on Computer Vision, Springer, Cham, 2020:741–757.
- [13] HOWARD A G, ZHU M, CHEN B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint. arXiv:1704.04861, 2017.
- [14] SANDLER M, HOWARD A, ZHU M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018:4510–4520.
- [15] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018:7132–7141.
- [16] YI D, LEI Z, LIAO S, et al. Learning face representation from scratch[J]. arXiv preprint. arXiv:1411.7923, 2014.
- [17] ZHANG K, ZHANG Z, LI Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks[J]. IEEE Signal Processing Letters, 2016, 23(10):1499–1503.
- [18] HUANG G B, MATTAR M, BERG T, et al. Labeled faces in the wild: A database for studying face recognition in unconstrained environments[C]// Workshop on Faces in ‘Real-Life’ Images: Detection, Alignment, and Recognition, 2008.
- [19] CHEN S, LIU Y, GAO X, et al. Mobilefacenet: Efficient CNNs for accurate real-time face verification on mobile devices[C]// Chinese Conference on Biometric Recognition, Springer, Cham, 2018:428–438.
- [20] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016:770–778.
- [21] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:10012–10022.
- [22] DONG X, BAO J, CHEN D, et al. CSWin transformer: A general vision transformer backbone with cross-shaped windows[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:12124–12134.

作者简介:

姜绍忠(1996—),男,硕士研究生,研究方向计算机视觉。

姚克明(1978—),男,通讯作者,博士,副教授,硕士研究生导师,主要研究领域为人工智能,图像处理等。

(上接第143页)

- [8] RAHIMI A, RECHT B. Random features for large-scale kernel machines[C]// Advances in Neural Information Processing Systems, 2007.
- [9] LI P, HASTIE T J, CHURCH K W. Very sparse random projections[C]// Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2006:287–296.
- [10] CHEN C L P, LIU Z. Broad learning system: An effective and efficient incremental learning system without the need for deep architecture[J]. IEEE Transactions on Neural Networks and Learning Systems, 2017, 29(1):10–24.
- [11] GONG X, ZHANG T, CHEN C L P, et al. Research review for broad learning system: Algorithms, theory, and applications[J]. IEEE Transactions on Cybernetics, 2022, 52:8922–8950.
- [12] LIU Z, CHEN C L P, ZHANG T, et al. Multi-kernel broad learning systems based on random features: A novel expansion for non-linear feature nodes[C]// IEEE International Conference on Systems, Man and Cybernetics (SMC), 2019:193–197.
- [13] 李旺. 稀疏的宽度学习系统及其应用研究[D]. 广州: 华南理工大学, 2019.
- Li Wang. Research on sparse width learning system and its application[D]. Guangzhou: South China University of Technology, 2019.
- [14] CHEN C, VONG C M, WONG C M, et al. Efficient extreme learning machine via very sparse random projection[J]. Soft Computing, 2018, 22(11):3563–3574.
- [15] HUANG H, RONG H J, YANG Z X, et al. Jointly evolving and compressing fuzzy system for feature reduction and classification[J]. Information Sciences, 2021, 579:218–230.
- [16] LENG Q, QI H, MIAO J, et al. One-class classification with extreme learning machine[J]. Mathematical Problems in Engineering, 2015, 2015:1–11.
- [17] SCHOLKOPF B, WILLIAMSON R C, SMOLA A J, et al. Support vector method for novelty detection[C]// NIPS, 1999:582–588.

作者简介:

周汉胜(1996—),男,硕士研究生,研究方向为机器学习。

李泽瑞(1991—),女,通讯作者,博士,特任副研究员,研究领域为机器学习。

周金华(1977—),男,博士,教授,研究领域为生物医学光学与图像处理。